



Uso de Aprendizado de Máquina na Modelagem Preditiva dos Valores de Imóveis na Cidade de João Pessoa

Gabriel de Jesus Pereira ¹

Pedro Rafael Diniz Marinho ²

Resumo

A urbanização no Brasil passou por profundas transformações ao longo do século XX. Em 1940, apenas 31% da população brasileira vivia em áreas urbanas; em 1970, esse número já havia superado os 50% (WAGNER; WARD, 1980), evidenciando um processo acelerado de transição demográfica impulsionado pelo êxodo rural e pela industrialização das principais capitais brasileiras. Esse movimento gerou uma crescente demanda habitacional, impulsionando a criação de instrumentos como o Sistema Financeiro de Habitação (SFH) e, posteriormente, o Sistema de Financiamento Imobiliário (SFI), fundamentais para estruturar o mercado imobiliário nacional. No cenário atual, a cidade de João Pessoa, PB, destaca-se com uma valorização acumulada de 16,13% nos imóveis residenciais até novembro de 2024, em comparação aos 12 meses anteriores, segundo a FIPE (2024), destacando-se entre as capitais com maior crescimento do setor. Diante desse contexto, este trabalho teve como objetivo desenvolver uma modelagem preditiva com base em algoritmos de aprendizado de máquina para estimar os valores de imóveis em João Pessoa. Para isso, foi construída uma base de dados com 31.781 observações a partir de técnicas de web scraping em sites de anúncios imobiliários, utilizando R e Python. Foram coletadas variáveis como valor de venda, localização, área, número de quartos, banheiros, vagas, tipo de imóvel e presença de atributos como varanda gourmet, sauna, piscina, entre outros. Além disso, foram incorporadas informações geográficas obtidas do INEP e do projeto Filipeia (Prefeitura de João Pessoa), utilizadas exclusivamente na construção da aplicação web. A base final incluiu 25 variáveis, sendo 11 quantitativas e 14 qualitativas. Durante a preparação dos dados, variáveis com muitos valores ausentes foram excluídas, e o restante dos dados faltantes foi tratado com imputação via KNN. Variáveis derivadas foram criadas com base em interações entre as variáveis mais correlacionadas, identificadas por meio da análise de correlação, e transformações como logaritmo e Yeo-Johnson foram aplicadas. As variáveis numéricas foram padronizadas e as categóricas codificadas por one-hot encoding. A modelagem foi conduzida com algoritmos baseados em árvores: Random Forest, Gradient Boosting, LightGBM, XGBoost e Stacking. A otimização de hiperparâmetros dos modelos foi realizada por meio de otimização bayesiana e validação cruzada de 20 folds. O modelo Gradient

¹ Departamento de Estatística - UFPB, Cidade Universitária, s/n, CEP 58051-900, João Pessoa - PB, Brasil - gabrielpereirapereiragabriel@gmail.com

² Departamento de Estatística - UFPB, Cidade Universitária, s/n, CEP 58051-900, João Pessoa - PB, Brasil - pedro.rafael.marinho@gmail.com



XIX ESCOLA DE MODELOS DE REGRESSÃO



Boosting obteve o melhor desempenho ($R^2 = 85,42\%$, $MAPE = 18,21\%$ e $RMSE = R\$ 227.677,44$), apresentando desempenho bastante semelhante aos demais modelos. Para compreender o comportamento das previsões e identificar as variáveis mais relevantes, foram aplicadas técnicas de interpretabilidade como SHAP, LIME, ICE e PDP. A área do imóvel, a razão entre o número de quartos e a área, vagas de garagem, localização e valor médio do aluguel foram as variáveis mais influentes. Ao final, foi desenvolvida uma aplicação web interativa que permite ao usuário estimar o valor de um imóvel com base no modelo que obteve o melhor ajuste. A ferramenta oferece diversos tipos de mapas, visualização de dados e permite a estimativa do valor com base nas características fornecidas pelo usuário.

Palavras-chave: Aprendizagem de máquina; modelagem; mercado imobiliário; aplicação web; João Pessoa.